Proyecto 1: Sistema Autónomo de Exploración y Decisión para un Rover

Elementos de Inteligencia Artificial — Curso 2026–2027

Estudiante: Cristina Hernández Fornaris

Resumen

En este trabajo se diseña, implementa y evalúa un sistema integral de toma de decisiones para un rover autónomo en entornos discretos con costos de terreno heterogéneos y recursos estrictamente limitados (batería, memoria y plazo temporal). El sistema adopta una arquitectura jerárquica de tres niveles: un estrato operativo de navegación mediante búsqueda informada (A^* con demostración empírica de dominancia); un estrato táctico de planificación clásica simbólica tipo STRIPS guiado por heurísticas causales que resuelve automáticamente el problema del marco y la gestión de recargas; y un estrato estratégico de metaheurísticas de trayectoria y poblacionales (Hill Climbing, Simulated Annealing y Algoritmo Genético) para la optimización de itinerarios científicos bajo un presupuesto uniforme de evaluaciones. Adicionalmente, se incorpora un sistema experto con motor de inferencia por encadenamiento hacia adelante (*forward chaining*) para la toma reactiva de decisiones ante situaciones de riesgo. La validez de los resultados se sustenta en un protocolo experimental estricto sobre cinco instancias parametrizadas por semillas, reportando medidas de tendencia central y dispersión ($\mu \pm \sigma$).

1. Introducción y Modelado del Entorno

La exploración autónoma en entornos planetarios desconocidos exige que un agente robótico tome decisiones complejas sin supervisión en tiempo real, priorizando objetivos científicos y calculando trayectorias mientras gestiona de forma rigurosa sus reservas energéticas y de almacenamiento [1].

1.1. Representación del Terreno como Grafo Ponderado

El entorno físico se modela formalmente como un grafo de rejilla bidimensional $G = (V, E)$ de dimensiones $W \times H$ con conectividad ortogonal regular de cuatro vecinos. Cada celda $u = (x, y) \in V$ representa una porción de terreno con una topografía específica a la que se asocia un costo de tránsito $c(u)$. En concreto, las superficies llanas y despejadas se definen con un costo unitario $c = 1{,}0$; las zonas de arena y dunas, con mayor resistencia al avance, poseen un costo $c = 2{,}0$; los sectores rocosos o pedregosos, de alta rugosidad y desgaste, se modelan con $c = 4{,}0$; y los obstáculos físicos insalvables reciben un costo infinito ($c = \infty$), marcando celdas intransitables. El costo de ejecutar una transición desde una celda u hasta un vecino ortogonal válido $v \in \text{Vecinos}(u)$ viene determinado por el costo de ocupación de la celda de destino, de modo que $\text{costo}(u, v) = c(v)$.

1.2. Entidades del Dominio y Generador Parametrizado

Para satisfacer el protocolo de reproducibilidad experimental, el entorno no se concibe como un mapa fijo, sino mediante una función determinista `generate_instance(width, height, num_pois, rock_ratio, seed)`. La Base de operaciones se sitúa en una celda transitable inicial y cuenta con un dispositivo de recarga que restaura la batería del vehículo a su capacidad máxima ($E_{\text{batería}} \leftarrow E_{\text{máx}}$). En el mapa se distribuyen estratégicamente entre una y dos Antenas de comunicación que delimitan un área de cobertura definida por una distancia Manhattan $r \leq 3$, dentro de la cual es físicamente factible emitir datos científicos. Asimismo, se incorporan K Puntos de Interés Científico (POIs) con coordenadas fijas (x_i, y_i) y una recompensa científica calibrada uniformemente $V_i \sim U(10{,}0, 100{,}0)$.

El vehículo opera bajo una reserva de batería acotada $E_{\text{máx}} \in [100, 150]$, un almacenamiento físico limitado a $M_{\text{máx}} = 3$ muestras y un horizonte temporal global $T_{\text{máx}} = 1000{,}0$.

Con este generador se estructuraron cinco instancias experimentales con dificultad progresiva: la Instancia 1 representa un escenario pequeño y favorable (15×15, 4 POIs, 10 % rocas, semilla 42); la Instancia 2 amplía el espacio a dificultad media (20×20, 5 POIs, 15 % rocas, semilla 101); la Instancia 3 introduce un terreno altamente agreste (20×20, 6 POIs, 25 % rocas, semilla 202); la Instancia 4 escala el problema a grandes distancias (25×25, 8 POIs, 15 % rocas, semilla 303); y la Instancia 5 plantea una misión de máxima exigencia combinatoria y energética (30×30, 10 POIs, 30 % rocas, semilla 404).

—

2. Módulo A: Búsqueda en Espacios de Estados

El estrato operativo del rover resuelve la navegación métrica sobre la cuadrícula entre cualquier par de coordenadas, encontrando caminos que minimicen el costo acumulado de movimiento.

2.1. Formulación Matemática del Problema

El espacio de estados se compone de las coordenadas transitables $(x, y) \in V$. El conjunto de acciones aplicables en un estado corresponde a los desplazamientos ortogonales hacia vecinos no bloqueados, $ACTIONS(x, y) = \{(x', y') \in \text{Vecinos}(x, y) \mid c(x', y') < \infty\}$, y la función de transición determina la ocupación de dicha celda. El costo de camino $g(n)$ acumula la suma de los costos individuales de cada casilla visitada.La verificación de estado meta se efectúa estrictamente al extraer y expandir el nodo de la cola de prioridad (`current == goal`). Comprobar la meta durante la fase de generación de sucesores provocaría la terminación prematura sobre caminos subóptimos ante costos variables, arruinando las garantías formales de A^* [1].

2.2. Heurísticas y Teorema de Dominancia

Para guiar la exploración se contrastaron cuatro algoritmos: Dijkstra, que actúa como línea base de búsqueda ciega ($f(n) = g(n)$); A^* con heurística Euclídea escalada por el costo mínimo unitario, $h_E(n) = \sqrt{(x - x_g)^2 + (y - y_g)^2}$; A^* con heurística Manhattan, $h_M(n) = |x - x_g| + |y - y_g|$; y Weighted A^*, definido mediante la función $f(n) = g(n) + w \cdot h_M(n)$ con factores de ponderación $w = 1{,}5$ y $w = 3{,}0$.

En una cuadrícula con conectividad a cuatro direcciones, el trayecto real está acotado inferiormente por la distancia rectilínea, cumpliéndose que $h_M(n) \geq h_E(n)$ para cualquier configuración espacial. Al ser ambas heurísticas admisibles y consistentes, la teoría de búsqueda informada demuestra que la heurística de mayor magnitud (h_M) domina a la menor (h_E). En virtud de este principio, cualquier nodo que A^* expanda de forma obligatoria bajo h_M ($f(n) < C^*$) necesariamente será expandido también bajo h_E, lo que garantiza que la heurística Manhattan explore un número estrictamente menor o igual de estados que la Euclídea sin sacrificar la optimalidad del camino. Por su parte, al fijar $w > 1$ en Weighted A^*, se renuncia deliberadamente a la admisibilidad matemática a cambio de acelerar la búsqueda hacia la meta, aceptando una solución subóptima cuyo costo queda formalmente acotado dentro de un factor constante $w \cdot C^*$.

—

3. Módulo B: Planificación Simbólica Clásica (STRIPS)

A diferencia de la búsqueda métrica en cuadrícula, donde el estado es atómico e indivisible, la planificación clásica descompone el estado del mundo en proposiciones lógicas (*fluents*) para determinar qué tareas realizar y en qué orden causal, sin requerir la especificación a priori de la longitud del plan [2].

3.1. Esquemas de Acción y Resolución del Problema del Marco

Las acciones se definen bajo el estándar STRIPS mediante parámetros, precondiciones de aplicabilidad y efectos divididos en listas de adición ($A\tilde{N}ADE$) y borrado ($BORRA$). Esta representación resuelve de manera implícita el problema del marco (*frame problem*): cualquier proposición que no figure en los efectos de una acción se asume invariante tras su ejecución. La acción Mover(pos_1, pos_2) exige que el agente se ubique en pos_1 y cuente con energía suficiente para el traslado, borrando la ubicación previa y añadiendo pos_2. La acción TomarMuestra(m, pos) requiere coincidir en la celda del POI y disponer de espacio libre en memoria ($M < 3$). El proceso continúa con Analizar(m), aplicable sobre muestras a bordo; Transmitir(m, pos), que exige cobertura de antena y borra la muestra de la memoria al considerarla completada; y Recargar(pos), condicionada a la presencia del rover en la Base para restablecer la batería al 100 %.

3.2. Integración de Niveles: Abstracción Simbólica y Navegación Física

La planificación opera sobre un espacio de alto nivel constituido exclusivamente por los enclaves de interés del mapa: la Base, las Antenas y los POIs. En lugar de evaluar transiciones celda a celda en el planificador, la acción de alto nivel Mover(k_i, k_j) delega su ejecución en el Módulo A. Éste invoca al algoritmo A^* con heurística Manhattan para obtener el costo acumulado óptimo y la trayectoria detallada sobre la cuadrícula. La exploración en el espacio de planes se formaliza mediante una búsqueda informada A^* sobre estados simbólicos, complementada con una política de poda causal que ejecuta de manera determinista las acciones locales aplicables en el nodo (Tomar → Analizar → Transmitir → Recargar), eliminando permutaciones superfluas y resolviendo planes complejos de más de 50 acciones en centésimas de segundo.

—

4. Módulo D: Metaheurísticas (Optimización de Recorrido)

4.1. Formulación Combinatoria y Decodificador Inteligente

Determinar la secuencia idónea para visitar los objetivos científicos constituye un problema derivado del Problema del Viajante con Restricciones y Beneficios (TSP / Orienteering). Al existir N puntos de interés, el espacio de soluciones posibles escala a razón de $N!$, volviendo inviable la búsqueda exhaustiva para valores moderados de N. La función de aptitud pondera el valor científico total recolectado y penaliza linealmente el costo de desplazamiento: $\text{Fitness}(S) = \sum_{i \in S} V_i - 0{,}1 \cdot \text{CostoTotal}(S) - \text{Penalización}(S)$.

Para resolver de raíz el riesgo de infactibilidad energética en misiones extensas, el evaluador del circuito incorpora un decodificador voraz de recarga. Mientras se simula el paso ordenado por los POIs del cromosoma, el sistema monitoriza el consumo de batería. Si la energía restante es insuficiente para alcanzar el siguiente objetivo y retornar con seguridad a la Base ($E < c(u, v) + c(v, \text{Base})$), el decodificador intercala automáticamente una parada intermedia en la Base, restaura la batería al máximo y prosigue con la ruta. Esta estrategia permite mantener una representación cromosómica limpia basada en permutaciones puras sin alterar los operadores genéticos.

4.2. Paradigmas Comparados bajo Presupuesto Idéntico

A fin de asegurar un marco experimental riguroso, todos los algoritmos se ejecutaron bajo un presupuesto idéntico de 5.000 evaluaciones de aptitud. Hill Climbing modela la búsqueda local voraz evaluando vecindarios basados en intercambio (*swap*) e inversión de segmentos (*2-opt*), avanzando únicamente ante ganancias estrictas. Simulated Annealing parte de una temperatura inicial $T_0 = 1000{,}0$ con factor de enfriamiento geométrico $\alpha = 0{,}995$; su capacidad probabilística para aceptar movimientos desfavorables mediante el criterio de Metropolis le permite sortear mesetas y escapar de cuencas subóptimas. Por último, el Algoritmo Genético mantiene una población de 50 individuos con selección por torneo ($k = 5$), operador de cruce especializado en permutaciones *Order Crossover* (OX) y mutación por intercambio aleatorio con tasa $p_m = 0{,}20$.

—

5. Módulo E: Sistema Experto Basado en Reglas

Se implementó en `src/rules.py` un sistema experto sustentado en un motor de inferencia por encadenamiento hacia adelante (*forward chaining*) con resolución de conflictos por prioridad (*salience*). Su objetivo es dotar al agente de capacidad reactiva supervisora ante cambios críticos en el entorno.

La base de conocimiento articula 14 reglas de producción organizadas en cuatro niveles de precedencia. En la cúspide (prioridad 105), la regla abstracta `R0` monitoriza los recursos globales y deduce hechos intermedios en la memoria de trabajo: si la batería cae por debajo del 28 % o el tiempo restante es inferior al 20 %, se afirma la proposición RoverVulnerable = True. En el estrato de seguridad vital (prioridades 100 a 90), si el rover se halla en base con carga parcial dispara `R1` (`RECARGAR`); si se detecta un margen crítico de retorno respecto a la distancia a base, se disparan `R2` o `R3`, emitiendo la orden inapelable `RETORNAR_A_BASE_EMERGENCIA`. En el nivel de comunicaciones (prioridad 82), la regla `R7` modela un comportamiento oportunista: si el vehículo cruza una celda en cobertura de antena y porta muestras procesadas, descarga la información de paso, liberando almacenamiento antes de que la memoria se sature. Finalmente, en el nivel estratégico (prioridad 40), la regla `R12` resuelve la selección dinámica del siguiente objetivo priorizando el ratio $\frac{\text{Valor Científico}}{\text{Distancia}}$.

—

6. Resultados Experimentales y Análisis Comparativo

El protocolo experimental fijó 15 corridas independientes por algoritmo e instancia estocástica, computando medias y desviaciones estándar sobre todas las métricas de desempeño.

6.1. Evaluación del Módulo A (Búsqueda)

Tabla 1: Comparativa de rendimiento en el Módulo A (15 rutas ortogonales evaluadas).

Algoritmo	**Costo** ($\mu \pm \sigma$)	**Nodos** ($\mu \pm \sigma$)	**Tiempo CPU (s)**	**Optimalidad**
Dijkstra (Costo Uniforme)	$18{,}20 \pm 11{,}63$	212 ± 185	$0{,}0010 \pm 0{,}0009$	Óptimo
A^* (Heurística Euclídea)	$18{,}20 \pm 11{,}63$	89 ± 92	$0{,}0004 \pm 0{,}0007$	Óptimo
A^* (Heurística Manhattan)	$18{,}20 \pm 11{,}63$	$\mathbf{67 \pm 67}$	$0{,}0005 \pm 0{,}0006$	Óptimo (Dominante)
Weighted A^* ($w = 1{,}5$)	$18{,}27 \pm 11{,}63$	31 ± 29	$0{,}0001 \pm 0{,}0003$	Subóptimo acotado
Weighted A^* ($w = 3{,}0$)	$20{,}73 \pm 13{,}50$	$\mathbf{16 \pm 10}$	$0{,}0001 \pm 0{,}0003$	Voraz (+13,9 % costo)

Los registros de la Tabla 1 corroboran empíricamente el teorema de dominancia. Dijkstra, A^* Euclídeo y A^* Manhattan convergen con exactitud al mismo costo promedio (18,20). No obstante, la heurística Manhattan reduce las expansiones a 67 nodos frente a los 89 de la Euclídea (un ahorro del 24.7 %) y frente a los 212 de Dijkstra (un 68.4 % menos de nodos explorados). Los resultados de Weighted A^* ilustran el compromiso ingeniería-recursos: ponderar con $w = 1{,}5$ permite podar el 53.7 % de los nodos de A^* con un sobrecosto inferior al 0.4 %, mientras que elevar el peso a $w = 3{,}0$ produce una exploración casi lineal (16 nodos) a expensas de encarecer la ruta un 13.9 %.

6.2. Comportamiento de la Planificación Simbólica

Tabla 2: Planes de misión sintetizados por el Planificador Clásico STRIPS.

Instancia	Dimensión / Terreno	POIs	Longitud del Plan	Costo Total	Recargas Insertadas
I1	15×15 (Fácil)	4	19 acciones	86.00	1 en Base
I2	20×20 (Normal)	5	23 acciones	82.00	0 (autónomo)
I3	20×20 (Rocoso)	6	29 acciones	165.00	1 en Base
I4	25×25 (Normal)	8	38 acciones	188.00	1 en Base
I5	30×30 (Difícil)	10	51 acciones	487.00	**3 en Base**

Como refleja la Tabla 2, el planificador respeta la causalidad física: en todas las misiones el número de acciones de recolección, análisis y transmisión equivale con precisión a la cantidad de POIs presentes. La complejidad se traslada a las acciones de desplazamiento y soporte: en la Instancia 5, donde confluyen un mapa de 30×30, 10 objetivos y un 30 % de suelo rocoso, el vehículo no puede completar la exploración con su carga nominal ($E_{\text{máx}} \approx 100$). El planificador resuelve esta tensión insertando de manera autónoma tres maniobras de retorno y recarga en la Base, culminando en un plan robusto de 51 acciones.

6.3. Comparativa de Metaheurísticas y Trampa de Óptimos Locales

Tabla 3: Desempeño agregado de las metaheurísticas (75 ejecuciones por técnica).

Algoritmo	Fitness ($\mu \pm \sigma$)	Costo ($\mu \pm \sigma$)	Valor Científico ($\mu \pm \sigma$)	Factibilidad
Hill Climbing	$364{,}45 \pm 120{,}45$	$189{,}83 \pm 193{,}34$	$383{,}43 \pm 128{,}44$	100.00 %
Simulated Annealing	$\mathbf{369{,}31 \pm 123{,}36}$	$\mathbf{141{,}19 \pm 126{,}13}$	$383{,}43 \pm 128{,}44$	**100.00 %**
Algoritmo Genético	$369{,}29 \pm 123{,}36$	$141{,}45 \pm 126{,}87$	$383{,}43 \pm 128{,}44$	100.00 %

Tabla 4: Comportamiento detallado en escenarios de alta dimensionalidad combinatoria.

Instancia	Algoritmo	Fitness ($\mu \pm \sigma$)	Costo Ruta ($\mu \pm \sigma$)	Factibilidad
I4 (8 POIs)	Hill Climbing	$544{,}50 \pm 2{,}18$	$177{,}40 \pm 21{,}77$	100.00 %
	Simulated Annealing	$\mathbf{549{,}74 \pm 0{,}20}$	$\mathbf{125{,}07 \pm 2{,}02}$	100.00 %
	Algoritmo Genético	$549{,}77 \pm 0{,}23$	$124{,}73 \pm 2{,}34$	100.00 %
I5 (10 POIs)	Hill Climbing	$392{,}23 \pm 5{,}31$	$525{,}27 \pm 53{,}08$	100.00 %
	Simulated Annealing	$\mathbf{408{,}67 \pm 0{,}44}$	$\mathbf{360{,}87 \pm 4{,}44}$	100.00 %
	Algoritmo Genético	$408{,}51 \pm 0{,}50$	$362{,}53 \pm 5{,}00$	100.00 %

El análisis comparativo de las Tablas 3 y 4 ilustra con nitidez el dilema entre exploración y explotación. En las instancias iniciales (I1 e I2, con $N \leq 5$), la reducida extensión del espacio de soluciones permite que los tres métodos alcancen el óptimo con idéntico fitness. No obstante, al escalar a 8 y 10 POIs en I4 e I5, la presencia de múltiples óptimos locales hace fracasar a Hill Climbing. Al avanzar únicamente hacia estados que mejoren el costo de inmediato, la búsqueda local queda atrapada prematuramente, arrojando costos de 177,40 (frente a 125,07) en I4 y de 525,27 (frente a 360,87) en I5. Por el contrario, Simulated Annealing y el Algoritmo Genético muestran una robustez notable con dispersión casi nula ($\sigma \approx 0{,}4$ en fitness), logrando una reducción de costo de traslado superior al 31 % gracias a su capacidad de diversificación.

Se determinó que 15 corridas por instancia (75 por algoritmo) resultaron suficientes debido a la rápida estabilización de la varianza: para Simulated Annealing y el Algoritmo Genético, la desviación estándar del fitness fue prácticamente nula (0.50 0.50), lo que garantiza que las conclusiones se sostienen estadísticamente sin requerir mayor muestreo. Asimismo, debe señalarse con rigor que, con la evidencia numérica recabada, Simulated Annealing y el Algoritmo Genético son estadísticamente

indistinguibles en calidad de solución (369.31 ± 123.36 369.31±123.36 frente a 369.29 ± 123.36 369.29±123.36), superando ambos con claridad a Hill Climbing.

6.4. Validación Experimental del Sistema Experto

Las pruebas del motor de reglas corroboraron la correcta inferencia en cadena. En el estado inicial de cada misión, la regla estratégica `R12` seleccionó con precisión el objetivo con mayor rentabilidad relativa (por ejemplo, el POI 3 en I1 y el POI 8 en I5). Asimismo, al inducir de forma controlada una caída drástica de batería en celdas lejanas a la Base, el sistema activó la secuencia deductiva multinivel:

$$\texttt{R0_Inferir_Estado_Vulnerable} \longrightarrow \texttt{R3_Emergencia_Bateria_Retorno} \longrightarrow \texttt{R4_Politica_Modo_Vulnerable} \tag{1}$$

La memoria de trabajo actualizó el modo operativo a estado conservador, anuló cualquier desplazamiento hacia objetivos secundarios y forzó la orden prioritaria de retorno inmediato a la Base, salvaguardando la integridad del vehículo.

—

7. Discusión de Desafíos y Lecciones de Modelado

Durante la etapa de diseño e implementación surgieron dos desafíos técnicos mayores que pusieron de manifiesto la estrecha relación entre la representación teórica y la viabilidad computacional.

El primer obstáculo radicó en la granularidad espacial del planificador simbólico. En una implementación preliminar, la acción de movimiento se modeló de forma microscópica, intentando trasladar al rover paso a paso a cada casilla adyacente sobre la cuadrícula. Al aplicar una búsqueda en anchura estándar hacia adelante, el proceso degeneró en un árbol con factor de ramificación 4 y profundidad superior a 100 (4^{100} estados posibles), bloqueando la ejecución por agotamiento de memoria. Este tropiezo práctico validó el análisis de complejidad de Bylander [2]: la planificación proposicional ciega es intratable sin una formulación adecuada. La solución consistió en establecer una división de responsabilidades: el planificador opera en un nivel abstracto sobre enclaves clave ($\mathcal{K}$), mientras que delega la búsqueda métrica exacta de cada desplazamiento al algoritmo A^*, integrando ambos módulos de forma eficiente.

El segundo desafío se presentó en la factibilidad física del ordenamiento metaheurístico. Cuando las metaheurísticas evaluaban recorridos continuos como un problema TSP puro sin paradas intermedias, la Instancia 5 arrojó sistemáticamente un 0 % de factibilidad. El costo mínimo de visitar 10 objetivos dispersos sobre un mapa rocoso de 30×30 oscila entre 158 y 195 unidades de energía, superando con creces la capacidad nominal de la batería (100 unidades). El espacio de soluciones factibles para una sola salida era físicamente inexistente. La integración del decodificador voraz con desvío a recarga no solo elevó la factibilidad al 100 % en todas las técnicas, sino que armonizó las soluciones de la metaheurística con los resultados del planificador clásico, donde el costo óptimo de la misión con tres recargas intermedias se situó coherentemente en 487 unidades.

—

8. Conclusiones

El desarrollo integral de este proyecto demuestra que la ingeniería de sistemas inteligentes en dominios complejos no depende de un único algoritmo hegemónico, sino de la selección y articulación adecuada de diferentes paradigmas computacionales según el nivel de abstracción del problema.

En el plano operativo, la búsqueda informada mediante el algoritmo A^* con heurística Manhattan ha ratificado que la inyección de conocimiento formal del dominio reduce drásticamente el espacio de búsqueda sin renunciar a la optimalidad. En el estrato táctico, la planificación clásica simbólica tipo STRIPS se revela insustituible para gestionar la causalidad de acciones y recursos finitos cuando no se conoce la longitud del plan de antemano. En el nivel estratégico, las metaheurísticas estocásticas han demostrado su eficacia para doblegar la explosión factorial propia de los problemas de ordenamiento combinatorio, destacando la superioridad de Simulated Annealing y los Algoritmos Genéticos frente al

estancamiento de los métodos locales voraces. Por último, los sistemas basados en reglas proporcionan una capa reactiva determinista, explicable e imprescindible para garantizar la supervivencia del agente ante contingencias operativas imprevistas.

En conclusión, la clave del éxito del sistema radica en la estructura jerárquica adoptada: desacoplar la optimización global del itinerario, la secuenciación causal de tareas y la navegación métrica paso a paso permite transformar un problema globalmente intratable en un conjunto de subproblemas eficientes. Todo el código fuente documentado, los conjuntos de datos generados y los scripts de ejecución se encuentran disponibles en el repositorio público de GitHub, garantizando su total reproducibilidad experimental mediante una única llamada a `python experiments.py`.

—

Referencias

[1] Russell, S. y Norvig, P. (2020). *Artificial Intelligence: A Modern Approach* (4.ª ed.). Pearson. Capítulos 3 (Búsqueda en espacios de estados), 6 (Problemas de satisfacción de restricciones) y 11 (Planificación clásica).

[2] Bylander, T. (1994). The computational complexity of propositional STRIPS planning. *Artificial Intelligence*, 69(1-2), 165–204.